EXAMEN DE CBDE

13 de Juny del 2013

Instruccions: Respon cada pregunta al full corresponent.
L'examen dura 1 hora.
Nom i Cognoms:
PREGUNTA 1. A l'hora de dissenyar un sistema, dubtes entre emprar HBase (un key-value) i MongoDB (un document-store). Recorda que HBase implementa un índex clúster distribuït i MongoDB consistent hashing. En qualsevol cas, saps que l'esquema serà el següent:
Key: IdCiutat i IdPersona
Value / Document: Dades personals, dades ciutat i dades laborals
A més, saps que:
 A nivell d'aplicació existeix un diccionari que mapeja cada ciutat i persona al seu id corresponent El 90% de les cerques es fan per idCiutat i idPersona El 10% de les cerques té com objectiu trobar persones VIP (un dels atributs a les dades personals que es guarden al <i>value</i> o <i>document</i>) Només el 3% de les persones són VIP
Et pots abstreure del tamany de la base de dades i centrar-te en els aspectes de disseny que et dona l'enunciat. Justifica, breument, quina seria la teva elecció:

PREGUNTA 2. Considera els dos sistemes que es mostren a continuació:

Sistema 1: Base de dades centralitzada

- És una base de dades centralitzada amb un únic node
- La base de dades ocupa 12TB. Per simplicitat, assumeix que conté una única taula T amb totes les dades i n'hi ha 100.000.000 de tuples
- La latència de llegir de disc és de 5ms
- L'ample de banda màxim que pot aconseguir el disc és de 100Mb/s

Sistema 2: Base de dades distribuïda

- Consta de 3 nodes connectats per una LAN. Qualsevol d'ells pot llençar queries
- La base de dades ocupa 12Tb. Pots assumir que la taula T s'ha distribuït de forma uniforme entre els nodes mitjançant una fragmentació horitzontal. No hi ha replicació
- La latència de llegir de disc és de 5ms i la de la xarxa 1 ms
- L'ample de banda màxim que pot aconseguir el disc és de 100Mb/s
- Els nodes estan connectats a través d'una LAN amb ample de banda màxim de 10Mb/s

SELECT SUM(a) FROM T, on a és un atribut de T

Suposa que l'única query del sistema és:

No hi ha índexs ni cap altra estructura definida en el sistema.
En el millor cas, quant trigarà (en segons) en fer un accés seqüencial de T en el sistema 1?
Latència
Lectura seqüencial
Total
I en el sistema 2 en el millor cas?
Latència
Lectura seqüencial
Total
Suposa ara que la única query del sistema fos:
SELECT * FROM T WHERE $pk = 1$, on pk és la clau primària de T i té un B+ associat (pots suposar que el B+ està a memòria)
Que canviaria respecte a la pregunta anterior?

PREGUNTA 3. Volem tenir accés integrat a dues Bases de Dades (BD1 i BD2), la primera de les quals conté dues taules (T11 i T12), mentre que la segona conté una única taula (T2). Per tal de poder fer-ho, creiem que la millor arquitectura és disposar de dos *wrappers* i un *mediator*, tal com es pot veure a la figura.

SELECT T11.a, T12.b, T2.c

FROM T11, T12, T2

WHERE T11.link=T12.link AND T12.link=T2.link

AND T11.slicer="X";

T11 T12

Mediator

Wrapper1

Wrapper2

Omple la taula indicant per cada crida que calgui implementar (no necessàriament han de ser cinc) per obtenir el resultat de la consulta anterior, qui l'executaria (ja sigui el *mediator* o un dels dos *wrappers*) i a quina seqüència d'operacions d'àlgebra relacional hi correspon. Posa tant les crides com les operacions en l'ordre d'execució que consideris més adient.

Ordre Operacions algebraiques Executor 1. 2. 1 3. 1. 2. 2 3. 4. 1. 2. 3 3. 1. 2. 4 3. 4. 1. 2. 5 3.